0.1 Lema de Ortogonalidad

Lema 1. *Definamos el subespacio:*

$$\mathcal{S} = \operatorname{span}\{\mathcal{K}(\cdot, \mathbf{x}_1), \mathcal{K}(\cdot, \mathbf{x}_2), \ldots, \mathcal{K}(\cdot, \mathbf{x}_n)\} \subset \mathcal{H}_\mathcal{K}$$

Cualquier función $f \in \mathcal{H}_\mathcal{K}$ puede descomponerse de manera única como:

$$f = f_\parallel + f_\perp$$

donde $f_\parallel \in \mathcal{S}$ y $f_\perp \in \mathcal{S}^\perp$ (ortogonal a $\mathcal{S}$). Entonces, para todo $i = 1, \ldots, n$:

$$f(\mathbf{x}_i) = f_\parallel(\mathbf{x}_i)$$

Proof. Por la propiedad reproductora del kernel:

$$f(\mathbf{x}_i) = \langle f, \mathcal{K}(\cdot, \mathbf{x}_i)\rangle_{\mathcal{H}_\mathcal{K}} = \left\langle f_\parallel + f_\perp, \mathcal{K}(\cdot, \mathbf{x}_i)\right\rangle_{\mathcal{H}_\mathcal{K}} = \left\langle f_\parallel, \mathcal{K}(\cdot, \mathbf{x}_i)\right\rangle_{\mathcal{H}_\mathcal{K}} + \langle f_\perp, \mathcal{K}(\cdot, \mathbf{x}_i)\rangle_{\mathcal{H}_\mathcal{K}}$$

Como $f_\perp \in \mathcal{S}^\perp$ y $\mathcal{K}(\cdot, \mathbf{x}_i) \in \mathcal{S}$, el segundo término se anula:

$$\langle f_\perp, \mathcal{K}(\cdot, \mathbf{x}_i)\rangle_{\mathcal{H}_\mathcal{K}} = 0$$

Además, nuevamente por la propiedad reproductora:

$$\left\langle f_\parallel, \mathcal{K}(\cdot, \mathbf{x}_i)\right\rangle_{\mathcal{H}_\mathcal{K}} = f_\parallel(\mathbf{x}_i)$$

Por lo tanto, $f(\mathbf{x}_i) = f_\parallel(\mathbf{x}_i)$ para todo i. □

Lema 2. *Para la descomposición $f = f_\parallel + f_\perp$ se cumple:*

$$\|f\|^2_{\mathcal{H}_\mathcal{K}} = \|f_\parallel\|^2_{\mathcal{H}_\mathcal{K}} + \|f_\perp\|^2_{\mathcal{H}_\mathcal{K}} \geq \|f_\parallel\|^2_{\mathcal{H}_\mathcal{K}}$$

Proof. Por el Teorema de Pitágoras en espacios de Hilbert, ya que $f_\parallel \perp f_\perp$. □

0.2 Demostración principal

Demostración del Teorema del Representador. Sea $f \in \mathcal{H}_\mathcal{K}$ cualquier función. Descompongamos $f = f_\parallel + f_\perp$ como en el Lema 1.

Paso 1: El funcional objetivo depende solo de $f_\parallel$. Evaluamos el funcional $J(f)$:

$$J(f) = \sum_{i=1}^{n} (y_i - f(\mathbf{x}_i))^2 + \lambda \|f\|_{\mathcal{H}_\mathcal{K}}^2$$

Por el Lema 1, $f(\mathbf{x}_i) = f_\parallel(\mathbf{x}_i)$ para todo i, por lo que el primer término se puede reescribir como:

$$\sum_{i=1}^{n} \big(y_i - f_\parallel(\mathbf{x}_i)\big)^2$$

Por el Lema 2, $\|f\|_{\mathcal{H}_\mathcal{K}}^2 = \|f_\parallel\|_{\mathcal{H}_\mathcal{K}}^2 + \|f_\perp\|_{\mathcal{H}_\mathcal{K}}^2$.

Sustituyendo:

$$J(f) = \sum_{i=1}^{n} \big(y_i - f_\parallel(\mathbf{x}_i)\big)^2 + \lambda \left(\|f_\parallel\|_{\mathcal{H}_\mathcal{K}}^2 + \|f_\perp\|_{\mathcal{H}_\mathcal{K}}^2\right)$$

Paso 2: Acotación del funcional. Separando los términos:

$$J(f) = \underbrace{\sum_{i=1}^{n} \big(y_i - f_\parallel(\mathbf{x}_i)\big)^2 + \lambda \|f_\parallel\|_{\mathcal{H}_\mathcal{K}}^2}_{J(f_\parallel)} + \lambda \|f_\perp\|_{\mathcal{H}_\mathcal{K}}^2$$

Como $\lambda > 0$ y $\|f_\perp\|_{\mathcal{H}_\mathcal{K}}^2 \geq 0$, tenemos:

$$J(f) \geq J(f_\parallel)$$

La igualdad ocurre si y solo si $f_\perp = 0$.

Paso 3: Caracterización del minimizador. Por lo tanto, para cualquier $f \in \mathcal{H}_\mathcal{K}$:

$$J(f) \geq J(f_\parallel)$$

Esto significa que el mínimo global f^* debe satisfacer $f_\perp^* = 0$, es decir:

$$f^* \in \mathcal{S}$$

En consecuencia, f^* se puede escribir como combinación lineal de los kernels evaluados en los puntos de entrenamiento:

$$f^*(\cdot) = \sum_{i=1}^{n} \alpha_i^* \, \mathcal{K}(\cdot, \mathbf{x}_i)$$

Paso 4: Obtención de los coeficientes. Sustituyendo esta expresión en el problema de optimización, evaluamos en los puntos de entrenamiento:

$$f^*(\mathbf{x}_j) = \sum_{i=1}^{n} \alpha_i^* \, \mathcal{K}(\mathbf{x}_j, \mathbf{x}_i) = \sum_{i=1}^{n} \alpha_i^* \, \mathbf{K}_{ji}$$

La norma en el RKHS se calcula como:

$$\|f^*\|_{\mathcal{H}_\mathcal{K}}^2 = \sum_{i=1}^{n} \sum_{j=1}^{n} \alpha_i^* \alpha_j^* \, \mathcal{K}(\mathbf{x}_i, \mathbf{x}_j) = (\boldsymbol{\alpha}^*)^T \mathbf{K} \boldsymbol{\alpha}^*$$

El funcional objetivo se convierte en:

$$J(\boldsymbol{\alpha}) = \|\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}\|_2^2 + \lambda \, \boldsymbol{\alpha}^T \mathbf{K} \boldsymbol{\alpha}$$

Derivamos con respecto a $\boldsymbol{\alpha}$ e igualamos a cero:

$$\nabla_{\boldsymbol{\alpha}} J = -2\mathbf{K}(\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}) + 2\lambda \mathbf{K}\boldsymbol{\alpha} = 0$$

$$-\mathbf{K}\mathbf{y} + \mathbf{K}^2\boldsymbol{\alpha} + \lambda \mathbf{K}\boldsymbol{\alpha} = 0$$

$$\mathbf{K}\left(-\mathbf{y} + (\mathbf{K} + \lambda \mathbf{I})\boldsymbol{\alpha}\right) = 0$$

Como $\mathbf{K}$ es definida positiva (para kernels estrictamente definidos positivos) o semidefinida positiva, y el término $\lambda \mathbf{I}$ asegura invertibilidad, podemos multiplicar por $\mathbf{K}^{-1}$ (en el sentido de la inversa de Moore-Penrose si es necesario):

$$(\mathbf{K} + \lambda \mathbf{I})\boldsymbol{\alpha} = \mathbf{y}$$

Por lo tanto:

$$\boldsymbol{\alpha}^* = (\mathbf{K} + \lambda \mathbf{I}_n)^{-1} \mathbf{y}$$

Paso 5: Unicidad. La matriz $\mathbf{K} + \lambda \mathbf{I}$ es estrictamente definida positiva (ya que $\lambda > 0$ y $\mathbf{K}$ es semidefinida positiva), por lo tanto es invertible y la solución es única. □

1 Corolario: Forma Predictiva

Corolario 1. *La función predictora de Kernel Ridge Regression para un nuevo punto* $\mathbf{x} \in \mathcal{X}$ *está dada por:*

$$\hat{f}(\mathbf{x}) = \sum_{i=1}^{n} \alpha_i^* \, \mathcal{K}(\mathbf{x}, \mathbf{x}_i) = \mathbf{k}(\mathbf{x})^T (\mathbf{K} + \lambda \mathbf{I})^{-1} \mathbf{y}$$

donde $\mathbf{k}(\mathbf{x}) = [\mathcal{K}(\mathbf{x}, \mathbf{x}_1), \ldots, \mathcal{K}(\mathbf{x}, \mathbf{x}_n)]^T$.

2 Consecuencias del Teorema

El Teorema del Representador tiene las siguientes implicaciones fundamentales:

1. **Reducción dimensional:** Un problema de optimización en un espacio de funciones de dimensión infinita se reduce a encontrar n coeficientes α_i.

2. **Kernel trick:** Solo necesitamos evaluar el kernel $\mathcal{K}$, nunca el mapeo explícito $\phi(\mathbf{x})$ al espacio de características.

3. **Solución cerrada:** Para KRR, existe una expresión analítica para los coeficientes $\boldsymbol{\alpha}^*$.

4. **Interpretabilidad:** Cada punto de entrenamiento $\mathbf{x}_i$ contribuye a la predicción con un peso α_i^*.

3 Planteamiento del Problema

Definición 1 (Problema de Kernel Ridge Regression)**.** *Dados* $\{(\mathbf{x}_i, y_i)\}_{i=1}^n \subset \mathcal{X} \times \mathbb{R}$*, un kernel definido positivo* $\mathcal{K} : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$*, su RKHS asociado* $\mathcal{H}_\mathcal{K}$*, y un parámetro de regularización* $\lambda > 0$*, el problema de KRR consiste en encontrar:*

$$\boxed{f^* = \arg\min_{f \in \mathcal{H}_\mathcal{K}} \; J(f) = \sum_{i=1}^n (y_i - f(\mathbf{x}_i))^2 + \lambda \|f\|_{\mathcal{H}_\mathcal{K}}^2}$$

El objetivo de este documento es demostrar que dicho minimizador f^* **existe** y es **único**.

4 Propiedades del Funcional Objetivo

Lema 3 (Estructura del funcional)**.** *El funcional* $J : \mathcal{H}_\mathcal{K} \to \mathbb{R}$ *puede reescribirse como:*

$$J(f) = \|\mathbf{y} - \mathbf{T}f\|_{\mathbb{R}^n}^2 + \lambda \|f\|_{\mathcal{H}_\mathcal{K}}^2$$

donde $\mathbf{T} : \mathcal{H}_\mathcal{K} \to \mathbb{R}^n$ *es el operador lineal de evaluación definido por:*

$$(\mathbf{T}f)_i = f(\mathbf{x}_i), \quad i = 1, \ldots, n$$

y $\mathbf{y} = (y_1, \ldots, y_n)^T \in \mathbb{R}^n$*.*

Proof. Es consecuencia directa de la definición de la norma euclidiana en $\mathbb{R}^n$:

$$\|\mathbf{y} - \mathbf{T}f\|_{\mathbb{R}^n}^2 = \sum_{i=1}^n (y_i - (\mathbf{T}f)_i)^2 = \sum_{i=1}^n (y_i - f(\mathbf{x}_i))^2$$

□

Lema 4 (Continuidad del operador de evaluación)**.** *El operador lineal de evaluación* $\mathbf{T} : \mathcal{H}_\mathcal{K} \to \mathbb{R}^n$ *es continuo (acotado). Específicamente, para todo* $f \in \mathcal{H}_\mathcal{K}$*:*

$$\|\mathbf{T}f\|_{\mathbb{R}^n} \leq \sqrt{n \cdot \kappa} \, \|f\|_{\mathcal{H}_\mathcal{K}}$$

donde $\kappa = \sup_{\mathbf{x} \in \mathcal{X}} \mathcal{K}(\mathbf{x}, \mathbf{x})$ *si el kernel es acotado.*

Proof. Por la propiedad reproductora del kernel:

$$|f(\mathbf{x}_i)| = |\langle f, \mathcal{K}(\cdot, \mathbf{x}_i)\rangle_{\mathcal{H}_\mathcal{K}}| \leq \|f\|_{\mathcal{H}_\mathcal{K}} \|\mathcal{K}(\cdot, \mathbf{x}_i)\|_{\mathcal{H}_\mathcal{K}} = \|f\|_{\mathcal{H}_\mathcal{K}} \sqrt{\mathcal{K}(\mathbf{x}_i, \mathbf{x}_i)}$$

Por lo tanto:

$$\|\mathbf{T}f\|^2_{\mathbb{R}^n} = \sum_{i=1}^{n} |f(\mathbf{x}_i)|^2 \leq \|f\|^2_{\mathcal{H}_\mathcal{K}} \sum_{i=1}^{n} \mathcal{K}(\mathbf{x}_i, \mathbf{x}_i) \leq n \cdot \kappa \|f\|^2_{\mathcal{H}_\mathcal{K}}$$

□

5 Existencia del Minimizador

Teorema 1 (Existencia)**.** *El problema de KRR tiene al menos un minimizador $f^* \in \mathcal{H}_\mathcal{K}$.*

Proof. Para demostrar la existencia, utilizamos el **Teorema de Existencia de Weierstrass** en espacios de Hilbert, que requiere:

(i) J es coercivo (es decir, $\lim_{\|f\|\to\infty} J(f) = \infty$)

(ii) J es débilmente semicontinuo inferior

Paso 1: Coercividad. Observemos que para cualquier $f \in \mathcal{H}_\mathcal{K}$:

$$J(f) = \sum_{i=1}^{n} (y_i - f(\mathbf{x}_i))^2 + \lambda \|f\|^2_{\mathcal{H}_\mathcal{K}} \geq \lambda \|f\|^2_{\mathcal{H}_\mathcal{K}}$$

Por lo tanto, si $\|f\|_{\mathcal{H}_\mathcal{K}} \to \infty$, entonces $J(f) \to \infty$. Esto establece la coercividad.

Paso 2: Semicontinuidad inferior débil. El funcional J es la suma de dos términos:

- $f \mapsto \|\mathbf{y} - \mathbf{T}f\|^2$ es convexa y continua (por la continuidad de $\mathbf{T}$), por lo tanto es débilmente semicontinua inferior.
- $f \mapsto \lambda \|f\|^2$ es convexa, continua y coerciva, por lo tanto también es débilmente semicontinua inferior.

La suma de funciones débilmente semicontinuas inferiores es débilmente semicontinua inferior.

Paso 3: Aplicación del Teorema de Weierstrass. Sea $\{f_k\}_{k\in\mathbb{N}}$ una sucesión minimizante, es decir:

$$\lim_{k\to\infty} J(f_k) = \inf_{f\in\mathcal{H}_\mathcal{K}} J(f) = m$$

Por la coercividad, la sucesión $\{f_k\}$ está acotada en $\mathcal{H}_\mathcal{K}$. Como $\mathcal{H}_\mathcal{K}$ es un espacio de Hilbert (y por tanto reflexivo), existe una subsucesión $\{f_{k_j}\}$ que converge débilmente a algún $f^* \in \mathcal{H}_\mathcal{K}$:

$$f_{k_j} \rightharpoonup f^*$$

Por la semicontinuidad inferior débil de J:

$$J(f^*) \leq \liminf_{j\to\infty} J(f_{k_j}) = m$$

Pero m es el ínfimo, por lo tanto $J(f^*) = m$. Así, f^* es un minimizador. $\square$

6 Unicidad del Minimizador

Teorema 2 (Unicidad)**.** *El minimizador f^* del problema de KRR es único.*

Proof. Demostramos la unicidad demostrando que J es **estrictamente convexo**.

Paso 1: Convexidad de los términos. El funcional J se compone de:

$$J(f) = \underbrace{\|\mathbf{y} - \mathbf{T}f\|^2}_{\text{convexo}} + \underbrace{\lambda\|f\|^2}_{\text{estrictamente convexo}}$$

- La función $f \mapsto \|\mathbf{y} - \mathbf{T}f\|^2$ es convexa (es una forma cuadrática con matriz $\mathbf{T}^T\mathbf{T}$ semidefinida positiva).
- La función $f \mapsto \lambda\|f\|^2$ es **estrictamente convexa**, ya que la norma al cuadrado en un espacio de Hilbert es estrictamente convexa.

Paso 2: Suma de funciones convexas. La suma de una función convexa y una función estrictamente convexa es **estrictamente convexa**.

Para verificar, tomemos $f \neq g$ en $\mathcal{H}_\mathcal{K}$ y $t \in (0,1)$:

$$\begin{aligned} J(tf + (1-t)g) &= \|\mathbf{y} - \mathbf{T}(tf + (1-t)g)\|^2 + \lambda\|tf + (1-t)g\|^2 \\ &= \|t(\mathbf{y} - \mathbf{T}f) + (1-t)(\mathbf{y} - \mathbf{T}g)\|^2 + \lambda\|tf + (1-t)g\|^2 \end{aligned}$$

Por la convexidad estricta de $\|\cdot\|^2$ en $\mathbb{R}^n$ y en $\mathcal{H}_\mathcal{K}$:

$$\begin{gathered} \|t(\mathbf{y} - \mathbf{T}f) + (1-t)(\mathbf{y} - \mathbf{T}g)\|^2 < t\|\mathbf{y} - \mathbf{T}f\|^2 + (1-t)\|\mathbf{y} - \mathbf{T}g\|^2 \\ \|tf + (1-t)g\|^2 < t\|f\|^2 + (1-t)\|g\|^2 \end{gathered}$$

(donde la primera desigualdad es estricta si $\mathbf{T}f \neq \mathbf{T}g$, y la segunda es siempre estricta porque $f \neq g$ y $\|\cdot\|^2$ es estrictamente convexo).

Sumando y multiplicando por $\lambda > 0$:

$$J(tf + (1-t)g) < tJ(f) + (1-t)J(g)$$

Paso 3: Consecuencia de la convexidad estricta. Supongamos que existen dos minimizadores distintos f^* y g^* con $f^* \neq g^*$ y $J(f^*) = J(g^*) = m$. Entonces, para cualquier $t \in (0,1)$:

$$J(tf^* + (1-t)g^*) < tJ(f^*) + (1-t)J(g^*) = tm + (1-t)m = m$$

Esto contradice que m es el valor mínimo (pues encontramos un punto con valor menor que m). Por lo tanto, no pueden existir dos minimizadores distintos.

Conclusión: El minimizador es único. □

7 Demostración Alternativa: Enfoque Matricial

Existe una demostración más directa trabajando en el subespacio $\mathcal{S} = \text{span}\{\mathcal{K}(\cdot, \mathbf{x}_i)\}$.

Demostración alternativa. Por el Teorema del Representador, cualquier minimizador tiene la forma:

$$f(\cdot) = \sum_{j=1}^{n} \alpha_j \mathcal{K}(\cdot, \mathbf{x}_j)$$

El funcional J se reduce a:

$$J(\boldsymbol{\alpha}) = \|\mathbf{y} - \mathbf{K}\boldsymbol{\alpha}\|_{\mathbb{R}^n}^2 + \lambda \boldsymbol{\alpha}^T \mathbf{K} \boldsymbol{\alpha}$$

donde $\mathbf{K}_{ij} = \mathcal{K}(\mathbf{x}_i, \mathbf{x}_j)$ es la matriz de Gram, que es semidefinida positiva.

Existencia: Expandamos:

$$J(\boldsymbol{\alpha}) = \mathbf{y}^T\mathbf{y} - 2\mathbf{y}^T\mathbf{K}\boldsymbol{\alpha} + \boldsymbol{\alpha}^T\mathbf{K}^T\mathbf{K}\boldsymbol{\alpha} + \lambda\boldsymbol{\alpha}^T\mathbf{K}\boldsymbol{\alpha}$$

La matriz hessiana de J es:

$$\mathbf{H} = 2\mathbf{K}^T\mathbf{K} + 2\lambda\mathbf{K} = 2\mathbf{K}(\mathbf{K} + \lambda\mathbf{I})$$

Como $\lambda > 0$ y $\mathbf{K}$ es semidefinida positiva, $\mathbf{K} + \lambda\mathbf{I}$ es definida positiva. Por lo tanto $\mathbf{H}$ es definida positiva (pues $\mathbf{K}(\mathbf{K} + \lambda\mathbf{I})$ es congruente con una matriz definida positiva). En consecuencia, J es estrictamente convexa en $\boldsymbol{\alpha}$ y tiene un único mínimo.

Unicidad: Derivando e igualando a cero:

$$\nabla_{\boldsymbol{\alpha}} J = -2\mathbf{K}\mathbf{y} + 2\mathbf{K}^2\boldsymbol{\alpha} + 2\lambda\mathbf{K}\boldsymbol{\alpha} = 0$$

$$\mathbf{K}(-\mathbf{y} + (\mathbf{K} + \lambda\mathbf{I})\boldsymbol{\alpha}) = 0$$

Como $\mathbf{K}+\lambda\mathbf{I}$ es invertible, multiplicamos por $\mathbf{K}^{-1}$ (en el sentido de la inversa de Moore-Penrose si $\mathbf{K}$ no es invertible) para obtener:

$$(\mathbf{K} + \lambda\mathbf{I})\boldsymbol{\alpha} = \mathbf{y}$$

$$\boldsymbol{\alpha}^* = (\mathbf{K} + \lambda\mathbf{I})^{-1}\mathbf{y}$$

Esta solución es única porque $\mathbf{K} + \lambda\mathbf{I}$ es invertible. □

8 Corolario: Caracterización del Minimizador

Corolario 2. *El único minimizador f^* de KRR satisface la siguiente ecuación variacional:*

$$\langle f^*, g\rangle_{\mathcal{H}_\mathcal{K}} = \frac{1}{\lambda}\sum_{i=1}^{n}(y_i - f^*(\mathbf{x}_i))g(\mathbf{x}_i), \quad \forall g \in \mathcal{H}_\mathcal{K}$$

Proof. La condición de optimalidad de primer orden (derivada de Gateaux) para J en f^* es:

$$\frac{d}{dt}J(f^* + tg)\bigg|_{t=0} = 0, \quad \forall g \in \mathcal{H}_\mathcal{K}$$

Calculando:

$$\frac{d}{dt}\left[\sum_{i=1}^{n}(y_i - f^*(\mathbf{x}_i) - tg(\mathbf{x}_i))^2 + \lambda\|f^* + tg\|^2\right]\bigg|_{t=0} = 0$$

$$\sum_{i=1}^{n} -2(y_i - f^*(\mathbf{x}_i))g(\mathbf{x}_i) + 2\lambda\left\langle f^*, g\right\rangle_{\mathcal{H}_\mathcal{K}} = 0$$

$$\lambda\left\langle f^*, g\right\rangle_{\mathcal{H}_\mathcal{K}} = \sum_{i=1}^{n}(y_i - f^*(\mathbf{x}_i))g(\mathbf{x}_i), \quad \forall g \in \mathcal{H}_\mathcal{K}$$

□

9 Conclusión

Resultado Final:

El problema de Kernel Ridge Regression tiene una única solución $f^* \in \mathcal{H}_\mathcal{K}$ dada por:

$$f^*(\cdot) = \sum_{i=1}^{n}\alpha_i^*\mathcal{K}(\cdot, \mathbf{x}_i), \quad \boldsymbol{\alpha}^* = (\mathbf{K} + \lambda\mathbf{I})^{-1}\mathbf{y}$$

La existencia se debe a la **coercividad** y la **semicontinuidad inferior débil** de J. La unicidad se debe a la **convexidad estricta** de J, garantizada por $\lambda > 0$.

10 Planteamiento del Problema

Definición 2 (Regularización de Tikhonov)**.** *Sean* $\{(\mathbf{x}_i, y_i)\}_{i=1}^n \subset \mathcal{X} \times \mathbb{R}$ *un conjunto de datos,* $\mathcal{H}$ *un espacio de Hilbert de funciones* $f : \mathcal{X} \to \mathbb{R}$*, y* $\lambda > 0$ *un parámetro de regularización. El problema de regularización de Tikhonov consiste en:*

$$\boxed{\min_{f \in \mathcal{H}} \; J(f) = \sum_{i=1}^{n} (y_i - f(\mathbf{x}_i))^2 + \lambda \|f\|_{\mathcal{H}}^2}$$

Teorema 3 (Existencia y Unicidad)**.** *Para* $\mathcal{H}$ *un espacio de Hilbert, el funcional* $J : \mathcal{H} \to \mathbb{R}$ *definido anteriormente alcanza un mínimo único.*

11 Demostración

La demostración se divide en dos partes: primero probamos la existencia, luego la unicidad.

11.1 Existencia del Minimizador

Para demostrar la existencia, utilizaremos el **Teorema de Weierstrass** en espacios de Hilbert, que requiere verificar dos condiciones:

1. J es **coercivo**: $J(f) \to \infty$ cuando $\|f\|_{\mathcal{H}} \to \infty$
2. J es **débilmente semicontinuo inferior** (w.s.c.i.)

Lema 5 (Coercividad)**.** *El funcional* J *es coercivo, es decir:*

$$\lim_{\|f\|_{\mathcal{H}} \to \infty} J(f) = \infty$$

Proof. Observemos que:

$$J(f) = \sum_{i=1}^{n} (y_i - f(\mathbf{x}_i))^2 + \lambda \|f\|_{\mathcal{H}}^2 \geq \lambda \|f\|_{\mathcal{H}}^2$$

ya que el primer término es no negativo. Por lo tanto:

$$J(f) \geq \lambda \|f\|_{\mathcal{H}}^2$$

Si $\|f\|_{\mathcal{H}} \to \infty$, entonces el lado derecho $\lambda \|f\|_{\mathcal{H}}^2 \to \infty$, y por consiguiente $J(f) \to \infty$. $\square$

Lema 6 (Continuidad de los funcionales de evaluación)**.** *Para cada $i = 1, \ldots, n$, el funcional lineal de evaluación $\delta_i : \mathcal{H} \to \mathbb{R}$ definido por $\delta_i(f) = f(\mathbf{x}_i)$ es continuo si $\mathcal{H}$ es un RKHS. En particular, cada δ_i es débilmente continuo.*

Proof. En un RKHS, por la propiedad reproductora:

$$|f(\mathbf{x}_i)| = |\langle f, K(\cdot, \mathbf{x}_i)\rangle| \leq \|f\|_{\mathcal{H}} \cdot \|K(\cdot, \mathbf{x}_i)\|_{\mathcal{H}} = \|f\|_{\mathcal{H}} \sqrt{K(\mathbf{x}_i, \mathbf{x}_i)}$$

Esto muestra que δ_i es acotado (y por tanto continuo). En espacios de Hilbert, los funcionales lineales continuos son también débilmente continuos. □

Lema 7 (Semicontinuidad inferior débil)**.** *El funcional J es débilmente semicontinuo inferior. Es decir, si $f_k \rightharpoonup f$ (convergencia débil en $\mathcal{H}$), entonces:*

$$J(f) \leq \liminf_{k\to\infty} J(f_k)$$

Proof. Escribimos J como suma de dos términos:

$$J(f) = A(f) + B(f)$$

donde $A(f) = \sum_{i=1}^{n}(y_i - f(\mathbf{x}_i))^2$ y $B(f) = \lambda\|f\|_{\mathcal{H}}^2$.

Para $A(f)$: La función $f \mapsto f(\mathbf{x}_i)$ es lineal y continua (Lema 2), por lo tanto es débilmente continua. La función $z \mapsto (y_i - z)^2$ es convexa y continua, y la composición de una función convexa continua con un funcional débilmente continuo es débilmente semicontinua inferior. La suma de funciones w.s.c.i. es w.s.c.i., por lo que A es w.s.c.i.

Para $B(f)$: La norma al cuadrado $\|f\|^2$ es convexa y continua, por lo tanto es débilmente semicontinua inferior (toda función convexa y continua es w.s.c.i. en espacios de Hilbert reflexivos).

Conclusión: La suma $J = A + B$ es w.s.c.i. por ser suma de funciones w.s.c.i. □

Teorema 4 (Existencia)**.** *El funcional J alcanza un mínimo en $\mathcal{H}$.*

Proof. Sea $\{f_k\}_{k\in\mathbb{N}} \subset \mathcal{H}$ una sucesión minimizante, es decir:

$$\lim_{k\to\infty} J(f_k) = \inf_{f\in\mathcal{H}} J(f) = m \in \mathbb{R} \cup \{-\infty\}$$

Paso 1: Acotación de la sucesión. Por el Lema 1 (coercividad), existe una constante $R > 0$ tal que para todo k suficientemente grande, $\|f_k\|_{\mathcal{H}} \leq R$. En caso contrario, existiría una subsucesión con $\|f_k\| \to \infty$ y entonces $J(f_k) \to \infty$, contradiciendo que $J(f_k) \to m$ finito.

Paso 2: Convergencia débil. Por el Teorema de Banach-Alaoglu (o porque $\mathcal{H}$ es reflexivo), toda sucesión acotada en un espacio de Hilbert posee una subsucesión débilmente convergente. Por lo tanto, existe una subsucesión $\{f_{k_j}\}$ y un elemento $f^* \in \mathcal{H}$ tal que:

$$f_{k_j} \rightharpoonup f^*$$

Paso 3: Aplicación de la semicontinuidad inferior. Por el Lema 3, J es w.s.c.i., por lo tanto:

$$J(f^*) \leq \liminf_{j\to\infty} J(f_{k_j}) = m$$

Pero m es el ínfimo de J, por definición $J(f^*) \geq m$. Por lo tanto:

$$J(f^*) = m$$

Así, f^* es un minimizador. □

11.2 Unicidad del Minimizador

Lema 8 (Convexidad estricta)**.** *El funcional J es estrictamente convexo para $\lambda > 0$.*

Proof. Verificamos la definición de convexidad estricta: para $f \neq g$ y $t \in (0, 1)$,

$$J(tf + (1-t)g) < tJ(f) + (1-t)J(g)$$

$$\begin{aligned} J(tf + (1-t)g) &= \sum_{i=1}^{n} \left(y_i - [tf(\mathbf{x}_i) + (1-t)g(\mathbf{x}_i)]\right)^2 + \lambda\|tf + (1-t)g\|^2 \\ &= \sum_{i=1}^{n} \left(t(y_i - f(\mathbf{x}_i)) + (1-t)(y_i - g(\mathbf{x}_i))\right)^2 + \lambda\|tf + (1-t)g\|^2 \end{aligned}$$

Para el primer término: La función $z \mapsto z^2$ es estrictamente convexa en $\mathbb{R}$. Por lo tanto:

$$(tu + (1-t)v)^2 \leq tu^2 + (1-t)v^2$$

con igualdad **solo si** $u = v$. Es decir:

$$\sum_{i=1}^{n} (t(y_i - f(\mathbf{x}_i)) + (1-t)(y_i - g(\mathbf{x}_i)))^2 \leq t \sum_{i=1}^{n} (y_i - f(\mathbf{x}_i))^2 + (1-t) \sum_{i=1}^{n} (y_i - g(\mathbf{x}_i))^2$$

Para el segundo término: La norma al cuadrado $\|f\|^2$ es estrictamente convexa en cualquier espacio de Hilbert. Por lo tanto, para $f \neq g$:

$$\|tf + (1-t)g\|^2 < t\|f\|^2 + (1-t)\|g\|^2$$

Multiplicando por $\lambda > 0$ y sumando ambas desigualdades, obtenemos:

$$J(tf + (1-t)g) < tJ(f) + (1-t)J(g)$$

Esto demuestra que J es estrictamente convexo. □

Teorema 5 (Unicidad)**.** *El minimizador de J es único.*

Proof. Supongamos que existen dos minimizadores distintos f^* y g^* con $f^* \neq g^*$ y $J(f^*) = J(g^*) = m$. Por el Lema 4 (convexidad estricta), para cualquier $t \in (0, 1)$:

$$J(tf^* + (1-t)g^*) < tJ(f^*) + (1-t)J(g^*) = tm + (1-t)m = m$$

Esto contradice el hecho de que m es el valor mínimo de J (pues hemos encontrado un punto con valor menor). Por lo tanto, no pueden existir dos minimizadores distintos. □

12 Conclusión

Resultado Final:
El problema de regularización de Tikhonov

$$\min_{f \in \mathcal{H}} \sum_{i=1}^{n} (y_i - f(\mathbf{x}_i))^2 + \lambda \|f\|_{\mathcal{H}}^2$$

tiene una única solución $f^* \in \mathcal{H}$ para todo $\lambda > 0$.

- La **existencia** se debe a la coercividad y la semicontinuidad inferior débil de J.
- La **unicidad** se debe a la convexidad estricta de J, garantizada por $\lambda > 0$.

13 Observaciones Adicionales

Proposición 1 (Dependencia continua en los datos)**.** *La solución f^* depende continuamente de los datos $\mathbf{y} \in \mathbb{R}^n$ cuando $\lambda > 0$ es fijo.*

Proof. En la representación dual (cuando $\mathcal{H}$ es un RKHS), la solución está dada por $\boldsymbol{\alpha}^* = (\mathbf{K} + \lambda \mathbf{I})^{-1}\mathbf{y}$. Como $\mathbf{K} + \lambda \mathbf{I}$ es invertible, la aplicación $\mathbf{y} \mapsto \boldsymbol{\alpha}^*$ es lineal y continua, por lo tanto f^* depende continuamente de $\mathbf{y}$. □

14 Definiciones Preliminares

Definición 3 (Kernel Definido Positivo)**.** *Una función $\mathcal{K} : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ es **definida positiva** si para cualquier $n \in \mathbb{N}$, cualquier conjunto de puntos distintos $\{\mathbf{x}_1, \ldots, \mathbf{x}_n\} \subset \mathcal{X}$ y cualquier vector $\mathbf{c} = (c_1, \ldots, c_n)^T \in \mathbb{R}^n$, se cumple:*

$$\sum_{i=1}^{n} \sum_{j=1}^{n} c_i c_j \mathcal{K}(\mathbf{x}_i, \mathbf{x}_j) \geq 0$$

Definición 4 (Kernel Estrictamente Definido Positivo)**.** *Un kernel $\mathcal{K}$ es **estrictamente definido positivo** si, además de la condición anterior, la*

igualdad:

$$\sum_{i=1}^{n}\sum_{j=1}^{n} c_i c_j \mathcal{K}(\mathbf{x}_i, \mathbf{x}_j) = 0$$

implica que $\mathbf{c} = \mathbf{0}$ *(todos los coeficientes son cero).*

Definición 5 (Kernel RBF (Gaussiano))**.** *El kernel Radial Basis Function (RBF) o kernel Gaussiano se define como:*

$$\mathcal{K}_{RBF}(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|^2}{2\sigma^2}\right)$$

donde $\sigma > 0$ *es el parámetro de ancho de banda. Equivalentemente, con* $\gamma = \frac{1}{2\sigma^2}$*:*

$$\mathcal{K}_{RBF}(\mathbf{x}, \mathbf{z}) = \exp\left(-\gamma\|\mathbf{x} - \mathbf{z}\|^2\right), \quad \gamma > 0$$

15 Teorema Principal

Teorema 6. *El kernel RBF (Gaussiano) es* ***estrictamente definido positivo*** *en* $\mathbb{R}^d$ *para cualquier* $\sigma > 0$*.*

16 Demostraciones Alternativas

Presentamos tres demostraciones diferentes, cada una desde una perspectiva distinta.

16.1 Demostración 1: Usando la Transformada de Fourier

Esta demostración se basa en el teorema de Bochner y la inyectividad de la transformada de Fourier.

Lema 9 (Teorema de Bochner)**.** *Una función continua* $\mathcal{K} : \mathbb{R}^d \to \mathbb{R}$ *es definida positiva si y solo si es la transformada de Fourier de una medida finita positiva. Es decir:*

$$\mathcal{K}(\mathbf{x}) = \int_{\mathbb{R}^d} e^{-i\boldsymbol{\omega}^T\mathbf{x}} d\mu(\boldsymbol{\omega})$$

Lema 10 (Transformada de Fourier del kernel RBF)**.** *El kernel RBF puede escribirse como:*

$$\exp\left(-\gamma\|\mathbf{x}-\mathbf{z}\|^2\right) = \int_{\mathbb{R}^d} \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{\|\boldsymbol{\omega}\|^2}{4\gamma}\right) e^{-i\boldsymbol{\omega}^T(\mathbf{x}-\mathbf{z})} d\boldsymbol{\omega}$$

Demostración. Para el kernel RBF, sabemos que su transformada de Fourier es:

$$\mathcal{F}[\mathcal{K}](\boldsymbol{\omega}) = \left(\frac{\pi}{\gamma}\right)^{d/2} \exp\left(-\frac{\|\boldsymbol{\omega}\|^2}{4\gamma}\right) > 0$$

Ahora consideramos la forma cuadrática:

$$\sum_{i=1}^{n}\sum_{j=1}^{n} c_i c_j \mathcal{K}(\mathbf{x}_i, \mathbf{x}_j) = \sum_{i=1}^{n}\sum_{j=1}^{n} c_i c_j \exp\left(-\gamma\|\mathbf{x}_i - \mathbf{x}_j\|^2\right)$$

Usando la representación integral:

$$= \sum_{i=1}^{n}\sum_{j=1}^{n} c_i c_j \int_{\mathbb{R}^d} \frac{1}{(2\pi)^{d/2}} \left(\frac{\pi}{\gamma}\right)^{d/2} \exp\left(-\frac{\|\boldsymbol{\omega}\|^2}{4\gamma}\right) e^{-i\boldsymbol{\omega}^T(\mathbf{x}_i-\mathbf{x}_j)} d\boldsymbol{\omega}$$

Intercambiando suma e integral:

$$= \left(\frac{\pi}{\gamma}\right)^{d/2} \int_{\mathbb{R}^d} \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{\|\boldsymbol{\omega}\|^2}{4\gamma}\right) \left|\sum_{j=1}^{n} c_j e^{-i\boldsymbol{\omega}^T\mathbf{x}_j}\right|^2 d\boldsymbol{\omega}$$

Como el integrando es no negativo y la función exponencial es estrictamente positiva, la integral es:

- ≥ 0 (definido positivo)
- $= 0$ si y solo si $\sum_{j=1}^{n} c_j e^{-i\boldsymbol{\omega}^T\mathbf{x}_j} = 0$ para casi todo $\boldsymbol{\omega}$

La función $F(\boldsymbol{\omega}) = \sum_{j=1}^{n} c_j e^{-i\boldsymbol{\omega}^T\mathbf{x}_j}$ es una combinación lineal de exponenciales complejas. Si $F(\boldsymbol{\omega}) = 0$ para todo $\boldsymbol{\omega}$ en un conjunto de medida positiva, entonces necesariamente todos los coeficientes $c_j = 0$, ya que las funciones $\boldsymbol{\omega} \mapsto e^{-i\boldsymbol{\omega}^T\mathbf{x}_j}$ son linealmente independientes para puntos $\mathbf{x}_j$ distintos.

Por lo tanto, la igualdad a cero implica $\mathbf{c} = \mathbf{0}$, demostrando que el kernel es estrictamente definido positivo. □

16.2 Demostración 2: Usando Polinomios y Completitud

Esta demostración utiliza la expansión en serie de la exponencial.

Demostración. Escribimos el kernel RBF como una serie de potencias:

$$\exp\left(-\gamma\|\mathbf{x}-\mathbf{z}\|^2\right) = \sum_{k=0}^{\infty} \frac{(-\gamma)^k}{k!}\|\mathbf{x}-\mathbf{z}\|^{2k}$$

Para puntos $\mathbf{x}_i \in \mathbb{R}^d$, consideramos la matriz de Gram $\mathbf{K}$ con entradas $\mathbf{K}_{ij} = \exp(-\gamma\|\mathbf{x}_i - \mathbf{x}_j\|^2)$.

Supongamos que $\mathbf{c}^T\mathbf{K}\mathbf{c} = 0$ para algún $\mathbf{c} \neq 0$. Entonces:

$$\sum_{i,j} c_i c_j \left[\sum_{k=0}^{\infty} \frac{(-\gamma)^k}{k!}\|\mathbf{x}_i - \mathbf{x}_j\|^{2k}\right] = 0$$

Intercambiando el orden de suma (justificado por convergencia absoluta):

$$\sum_{k=0}^{\infty} \frac{(-\gamma)^k}{k!} \sum_{i,j} c_i c_j \|\mathbf{x}_i - \mathbf{x}_j\|^{2k} = 0$$

Definamos $S_k = \sum_{i,j} c_i c_j \|\mathbf{x}_i - \mathbf{x}_j\|^{2k}$.

Caso $k = 0$: $\|\mathbf{x}_i - \mathbf{x}_j\|^0 = 1$ (con la convención $0^0 = 1$ para $i = j$). Entonces:

$$S_0 = \sum_{i,j} c_i c_j = \left(\sum_i c_i\right)^2 \geq 0$$

Para $k \geq 1$: La función $\|\mathbf{x}-\mathbf{z}\|^{2k}$ es un kernel condicionalmente definido positivo de orden 1, pero no es directamente definido positivo. Necesitamos un argumento más refinado.

Usamos el hecho de que la función $\exp(-\gamma t)$ es completamente monótona y aplicamos el teorema de Schoenberg.

Teorema 7 (Schoenberg)**.** *Una función $\phi : [0, \infty) \to \mathbb{R}$ con $\phi(0) = 1$ da lugar a un kernel definido positivo $\mathcal{K}(\mathbf{x}, \mathbf{z}) = \phi(\|\mathbf{x}-\mathbf{z}\|^2)$ si y solo si ϕ es completamente monótona.*

La función $\phi(t) = e^{-\gamma t}$ es completamente monótona porque $(-1)^k \phi^{(k)}(t) = \gamma^k e^{-\gamma t} \geq 0$ para todo k. Además, es estrictamente completamente monótona (todas las derivadas son estrictamente positivas para $t > 0$).

La matriz de Gram puede escribirse como producto de Hadamard de matrices de rango 1. Se puede demostrar que para puntos distintos, si $\mathbf{c} \neq 0$, entonces $\mathbf{c}^T \mathbf{K} \mathbf{c} > 0$. □

16.3 Demostración 3: Usando Inducción y Determinantes

Esta demostración es más constructiva y utiliza las propiedades de los determinantes de matrices de Gram.

Lema 11 (Caracterización de estricta definición positiva)**.** *Un kernel $\mathcal{K}$ es estrictamente definido positivo si y solo si para cualquier conjunto de puntos distintos $\{\mathbf{x}_1, \ldots, \mathbf{x}_n\}$, la matriz de Gram $\mathbf{K}$ es definida positiva (todos sus autovalores son positivos).*

Demostración. Procedemos por inducción en n, el número de puntos.

Caso base $n = 1$: Para un solo punto $\mathbf{x}_1$, la matriz de Gram es $[\mathcal{K}(\mathbf{x}_1, \mathbf{x}_1)] = [1]$, que es definida positiva.

Paso inductivo: Supongamos que la matriz de Gram para cualquier conjunto de $n-1$ puntos distintos es definida positiva. Consideremos n puntos distintos $\mathbf{x}_1, \ldots, \mathbf{x}_n$ y la matriz $\mathbf{K}_n$.

Escribimos $\mathbf{K}_n$ en forma de bloques:

$$\mathbf{K}_n = \begin{pmatrix} \mathbf{K}_{n-1} & \mathbf{v} \\ \mathbf{v}^T & 1 \end{pmatrix}$$

donde $\mathbf{v} \in \mathbb{R}^{n-1}$ con entradas $v_i = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_n\|^2)$.

Por el lema del complemento de Schur, $\mathbf{K}_n$ es definida positiva si y solo si $\mathbf{K}_{n-1}$ es definida positiva y el complemento de Schur:

$$S = 1 - \mathbf{v}^T \mathbf{K}_{n-1}^{-1} \mathbf{v} > 0$$

Por hipótesis de inducción, $\mathbf{K}_{n-1}$ es definida positiva, así que tiene inversa. Falta demostrar que $S > 0$.

Observemos que $S = \det(\mathbf{K}_n)/\det(\mathbf{K}_{n-1})$. Por lo tanto, basta demostrar que $\det(\mathbf{K}_n) > 0$.

Para el kernel RBF, se puede demostrar que el determinante de la matriz de Gram es positivo para puntos distintos. Esto se sigue de que el kernel es **totalmente positivo** (de tipo TP). Una forma de verlo es notar que la matriz $\mathbf{K}_n$ puede escribirse como:

$$\mathbf{K}_n = \mathbf{B}^T\mathbf{B}$$

donde $\mathbf{B}$ es una matriz $N \times n$ con $N \to \infty$ (representación mediante características de Fourier aleatorias).

Como $\mathbf{B}$ tiene rango completo para puntos distintos (porque las funciones $\boldsymbol{\omega} \mapsto e^{-i\boldsymbol{\omega}^T\mathbf{x}_j}$ son linealmente independientes), la matriz $\mathbf{K}_n$ es definida positiva. □

17 Corolario: Implicaciones para KRR

Corolario 3. *Para el kernel RBF, la matriz de Gram* $\mathbf{K}$ *es definida positiva siempre que los puntos* $\mathbf{x}_1, \ldots, \mathbf{x}_n$ *sean distintos.*

Corolario 4. *En Kernel Ridge Regression con kernel RBF y* $\lambda > 0$*, la matriz* $\mathbf{K} + \lambda\mathbf{I}$ *es siempre invertible (definida positiva) y la solución es única.*

Proof. Como $\mathbf{K}$ es definida positiva, todos sus autovalores μ_i son estrictamente positivos. Entonces los autovalores de $\mathbf{K} + \lambda\mathbf{I}$ son $\mu_i + \lambda \geq \lambda > 0$, por lo tanto la matriz es invertible. □

18 Contraejemplo: Un Kernel que No es Estrictamente Definido Positivo

Para entender la importancia de la estricta definición positiva, consideremos el kernel lineal:

$$\mathcal{K}_{\text{lin}}(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T\mathbf{z}$$

Este kernel no es estrictamente definido positivo porque si tomamos tres puntos en $\mathbb{R}^2$: $\mathbf{x}_1 = (1, 0)$, $\mathbf{x}_2 = (0, 1)$, $\mathbf{x}_3 = (1, 1)$, y coeficientes $c_1 = 1$, $c_2 = 1$, $c_3 = -1$, entonces:

$$\sum_{i,j} c_i c_j \mathbf{x}_i^T \mathbf{x}_j = 0 \quad \text{pero} \quad \mathbf{c} \neq \mathbf{0}$$

Esto ocurre porque $\mathbf{K} = \mathbf{X}\mathbf{X}^T$ tiene rango 2, pero con 3 puntos la matriz es singular.

El kernel RBF, al ser estrictamente definido positivo, evita este problema: garantiza que la matriz de Gram tiene rango completo para cualquier conjunto de puntos distintos.