Kernel Ridge Regression

Luis Roca

El Problema de Regresión

Problema Fundamental

Dados n pares observados $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$ con $\mathbf{x}_i \in \mathcal{X} \subseteq \mathbb{R}^d$, $y_i \in \mathbb{R}$, buscamos:

$$f^* = \arg\min_{f \in \mathcal{F}} \sum_{i=1}^n (y_i - f(\mathbf{x}_i))^2$$

- **Dificultad:** El espacio $\mathcal{F}$ es demasiado grande $\Rightarrow$ sobreajuste
- **Solución clásica:** Restringir a funciones lineales $f(\mathbf{x}) = \mathbf{w}^T\mathbf{x} + b$
- **Limitación:** Incapacidad para capturar relaciones no lineales

¿Cómo extender la regresión lineal a espacios de funciones no lineales?

Espacios RKHS

Definición (Kernel)

Sea $\mathcal{X}$ un conjunto no vacío. Una función $\mathcal{K} : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ es llamada una función kernel si existe un espacio de Hilbert $\mathcal{H}$ y un mapeo $\phi : \mathcal{X} \to \mathcal{H}$ tal que para todo $\mathbf{x}, \mathbf{x}' \in \mathcal{X}$

$$\mathcal{K}(\mathbf{x}, \mathbf{x}') = \langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle_{\mathcal{H}}$$

$\mathcal{H}$ será llamado espacio de características y ϕ mapeo de características.

Definición (RKHS)

Un espacio de Hilbert $\mathcal{H}$ de funciones $f : \mathcal{X} \to \mathbb{R}$ es un **Espacio de Hilbert con Kernel Reproductor** si existe $\mathcal{K} : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ tal que:

1. $\mathcal{K}(\cdot, \mathbf{x}) \in \mathcal{H}$ para todo $\mathbf{x} \in \mathcal{X}$
2. **Propiedad reproductora:** $f(\mathbf{x}) = \langle f, \mathcal{K}(\cdot, \mathbf{x}) \rangle_{\mathcal{H}}$ $\forall f \in \mathcal{H}$, $\forall \mathbf{x} \in \mathcal{X}$

$\mathcal{K}$ sera llamado kernel reproductor.

Formulación Matemática

Definición (Kernel Ridge Regression)

Dados $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$, KRR resuelve:

$$\min_{f \in \mathcal{H}_\mathcal{K}} \sum_{i=1}^n (y_i - f(\mathbf{x}_i))^2 + \lambda \|f\|^2_{\mathcal{H}_\mathcal{K}}$$

Un paso decisivo es es probar que la solución de este problema pertenece a un subespacio de dimensión finita en el espacio de características. Es decir KRR es compatible con un teorema del representador:

$$f(\mathbf{x}) = \sum_{j=1}^n \alpha_j \mathcal{K}(\mathbf{x}, \mathbf{x}_j)$$

Teorema (Teorema del Representador para Kernel Ridge Regression)

Sean $\{(\mathbf{x}_i, y_i)\}_{i=1}^n \subset \mathcal{X} \times \mathbb{R}$ un conjunto de datos de entrenamiento, $\mathcal{K} : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ un kernel definido positivo, $\mathcal{H}_\mathcal{K}$ el RKHS asociado, y $\lambda > 0$ un parámetro de regularización. Entonces, el problema de optimización:

$$\boxed{\min_{f \in \mathcal{H}_\mathcal{K}} \; J(f) = \sum_{i=1}^n (y_i - f(\mathbf{x}_i))^2 + \lambda \|f\|_{\mathcal{H}_\mathcal{K}}^2}$$

tiene una única solución $f^* \in \mathcal{H}_\mathcal{K}$ que admite la representación:

$$\boxed{f^*(\cdot) = \sum_{i=1}^n \alpha_i^* \, \mathcal{K}(\cdot, \mathbf{x}_i)}$$

donde los coeficientes $\boldsymbol{\alpha}^* = (\alpha_1^*, \ldots, \alpha_n^*)^T \in \mathbb{R}^n$ están dados por:

$$\boxed{\boldsymbol{\alpha}^* = (\mathbf{K} + \lambda \mathbf{I}_n)^{-1} \mathbf{y}}$$

con $\mathbf{K}_{ij} = \mathcal{K}(\mathbf{x}_i, \mathbf{x}_j)$ la matriz de Gram (o matriz de kernel) y $\mathbf{y} = (y_1, \ldots, y_n)^T$.

Implicación Fundamental

La solución vive en el subespacio **de dimensión finita** generado por las funciones kernel centradas en los datos.

Kernels Comunes

Kernel RBF (Gaussiano)

$$\mathcal{K}_{\text{RBF}}(\mathbf{x}, \mathbf{x}') = \exp\left(-\frac{\|\mathbf{x} - \mathbf{x}'\|^2}{2\sigma^2}\right)$$

- Parámetro σ: escala de longitud
- Espacio RKHS infinito-dimensional

Kernel Polinomial

$$\mathcal{K}_{\text{poly}}(\mathbf{x}, \mathbf{x}') = (\mathbf{x}^T\mathbf{x}' + c)^d$$

- Características: monomios de grado $\leq d$
- Espacio de dimensión finita $\binom{d+p}{p}$

Kernel Lineal

$$\mathcal{K}_{\text{lin}}(\mathbf{x}, \mathbf{x}') = \mathbf{x}^T \mathbf{x}' \quad \Rightarrow \quad \text{Ridge regression estándar}$$

Implementación

https://colab.research.google.com/drive/1YAf-5TspCQiFqiAlLcWHf01DvrYg77hP?usp=sharing

Conclusiones

1. **KRR unifica** teoría de regularización, espacios RKHS y métodos de kernel
2. **Ventajas clave**:
   - Solución en forma cerrada (no optimización iterativa)
   - Manejo natural de no linealidades
   - Conexión profunda con teoría de aproximación
3. **Problemas computacionales**
   - **Complejidad** $\mathcal{O}(n^3)$: Inversión de matriz de Gram
   - **Memoria** $\mathcal{O}(n^2)$: Almacenamiento de $\mathbf{K}$
   - Impráctico para $n > 10^4$ (en hardware estándar)
4. **Desafíos actuales**:
   - Escalabilidad a grandes datasets
   - Selección automática de kernel
   - Teoría para datos no i.i.d. o dependientes

Referencias

- Berlinet, A., & Thomas-Agnan, C. (2011). *Reproducing Kernel Hilbert Spaces in Probability and Statistics*. Springer.
- Theodoridis, S. (2024). *Machine learning: from the classics to deep networks, transformers, and diffusion models*. Elsevier.
- Steinwart, I., & Christmann, A. (2008). *Support vector machines*. Springer Science & Business Media.
- Shawe-Taylor, J., & Cristianini, N. (2004). *Kernel Methods for Pattern Analysis*. Cambridge University Press.